

Pipelines

Лос пипелинес

Pipeline № 1. Data Analysis и ML (но ML — в более классическом понимании)

Цепочка пипелине	Что покрывает такой пипелине?
<pre> SQL ↓ pandas ↓ NumPy ↓ EDA ↓ Feature Engineering ↓ scikit-learn ↓ matplotlib </pre>	+ SQL-запросы + извлечение данных + очистка данных + обработка пропусков + работа с выбросами + статистика + EDA (ням-ням) + визуализацию + feature engineering + разделение на выборки (обучающая, тестовая) + классификация + регрессия + метрики качества + интерпретация моделей + прогнозирование + временные ряды (для чайников)

Например: прогноз продаж, прогноз оттока, кредитный скоринг, прогноз цен квартир, прогноз спроса.

Pipeline № 2. NLP и LLM

Цепочка пипелине	Что покрывает такой пипелине?
<pre> Pandas ↓ предобработка текста ↓ трансформеры (автоботы, вперёд!) ↓ PyTorch ↓ оценка (evaluation) ↓ визуализация </pre>	+ обработка текста + токенизация + эмбединги + классификация текстов + анализ тональности + поиск похожих документов + RAG-конвейеры (на базовом уровне) + работа с LLM + тонкая настройка (fine-tuning) + выводы (inference) + GPU-вычисления + современные Transformer-модели (Меня зовут Оптимус Прайм!)

Например: спам, отзывы, классификация документов, чат-боты.

Pipeline № 3. Deep Learning

Цепочка пипелине	Что покрывает такой пипелине?
Pandas ↓ NumPy ↓ PyTorch ↓ обучение ↓ оценка (evaluation) ↓ matplotlib	+ нейронные сети + градиентный спуск + backpropagation + работа с GPU + DataLoader + пакетная обработка (batching) + цикл обучения + цикл валидации + функции потерь + оптимизаторы + регуляризация + переобучение

ВАЖНО: НЕ покрывает SQL, EDA, работу с бизнес-данными, feature engineering.

Pipeline № 4. Research Workflow

Цепочка пипелине	Что покрывает такой пипелине?
Jupyter ↓ pandas ↓ NumPy ↓ эксперименты ↓ matplotlib ↓ отчёт	+ проведение исследований + постановка гипотез + воспроизводимость экспериментов + документирование результатов + научная визуализация + статистический анализ + сравнение моделей + оформление результатов + подготовка публикаций + работа в notebook-среде (например Jupyter)

Наука, все дела.

Pipeline № 5. Production Thinking

Цепочка пипелине	Что покрывает такой пипелине?
SQL ↓ pandas ↓ предобработка ↓ сохранённая модель ↓ выводы ↓ отчёт	+ понимание жизненного цикла модели + обучение — выводы + сериализация моделей + воспроизводимость preprocessing + пакетная обработку данных + мониторинг качества + подготовка данных для продакшена + обработка новых данных + понятие ML-сервиса + основы MLOps

Нам понадобятся пипелине 1 и 2.

Задание для № 1
Находим БД с продажами

Задание 1. SQL → pandas

Подключаемся к БД, делаем запрос, данные из БД загружаем в DataFrame (pandas)

Задание 2. Очистка данных

1. Найти пропуски
2. Найти дубликаты
3. Найти отрицательные цены
4. Найти продажи с отрицательным или нулевым количеством
5. Исправить ошибки

Задание 3. EDA и визуализация

Построить:

- гистограмму цен;
- ящик с усами (boxplot);
- продажи по месяцам;
- топ-10 товаров.

Посчитать:

- среднее;
- медиану;
- стандартное отклонение.

Задание 4. NumPy и статистика

Для столбца price рассчитать:

- среднее значение;
- медиану;
- дисперсию;
- стандартное отклонение;
- 25-й и 75-й перцентили.

Задание 5. Feature Engineering

Создать новые признаки

Некоторые признаки оказываются бесполезными, показать это на корреляционной матрице

Задание 6. Классификация клиентов

Обучить:

- Логистическую регрессию;
- Дерево решений.

Задание 7. Прогноз продаж

Использовать

- Линейную регрессию;
- Random Forest.

Оценить

- MAE;
- RMSE;
- R^2 .

Задание 8. Временные ряды

Рассчитать:

- Скользящее среднее (7 дней);
- Скользящее среднее (30 дней).

Задание 9. Полный ML Pipeline

Автоматизировать весь процесс. Использовать Pipeline() из sklearn. В pipeline включить масштабирование и обучение модели.

Задание для № 2 Находим текстовый датасет

Задание 1. Анализ текстового датасета

Посчитать:

- + число документов;
- + среднюю длину текста;
- + самые частые слова.

Задание 2. Очистка текста

Удалить:

- + HTML;
- + URL;
- + спецсимволы;
- + лишние пробелы.

Задание 3. Tokenizer

Использовать tokenizer. Получить input_ids и attention_mask.

Задание 4. Inference готовой модели

Использовать готовую модель для:

- анализа тона;
- классификации текста.

Задание 5. Сравнение моделей

Вариант 1

TF-IDF + Logistic Regression

Вариант 2

Transformer

Сравнить

- точность;
- время работы;
- потребление памяти.

Задание 6. Embeddings

Требуется получить эмбединги предложений.

Рассчитать:

- косинусовое сходство;
- наиболее похожие тексты.

Задание 7. Fine-tuning

Требуется дообучить готовую модель на своём датасете.

Задание 8. Анализ ошибок модели

Требуется найти:

- false positives;
- false negatives.

Задание 9. PyTorch под капотом

Реализовать простую нейросеть на PyTorch без трансформеров и десептиконов.